AFDB – DATA INNOVATION FOR AFRICA (DI4A)

Un indice de prix à partir du web

Trois carnets, huit pays, deux familles de sources : le commerce en ligne et les publications officielles.

68 884
produits

53 149
relevés officiels

277
tests

Chiffres mesurés le 2026-10-28 à 12:10

PARCOURS

Ce que cette présentation couvre

1. **L'objectif**
   ce qu'on cherche à mesurer, et ce qu'on ne mesure pas
2. **Les concepts**
   COICOP, panier, variété, SKU, modèles appariés, pondération
3. **L'enchaînement**
   la figure du dispositif, des sites à l'indice
4. **Les trois carnets**
   objectif, sources, sorties ; la classification
5. **Les calculs**
   chaque mesure détaillée sur un exemple réel
6. **L'exécution**
   installer, lancer, reprendre une collecte
7. **Les données**
   ce qui est collecté, pays par pays
8. **Portée et limites**
   ce que le dispositif vaut, et où il s'arrête

Le problème

Un indice des prix à la consommation se relève sur le terrain : des enquêteurs notent des prix dans des points de vente, **chaque mois**.

C'est lent, coûteux, et cela ne couvre que ce qu'on va voir.

LA QUESTION

Le web publie des prix en continu, gratuitement et massivement. **Que peut-on en tirer pour la statistique publique, et à quelles conditions ?**

Ce dispositif répond en construisant la chaîne entière — collecte, classification, indice — sur **huit pays africains**, et en mesurant ce qu'elle vaut.

Ce qu'on produit, ce qu'on ne produit pas

PRODUIT

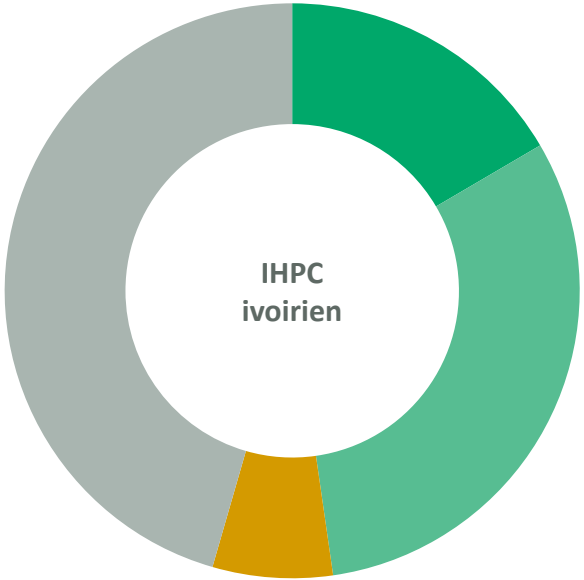
- des relevés de prix horodatés, par produit et par pays
- une classification COICOP 2018 de chaque produit
- des indices élémentaires et agrégés, plusieurs formules
- une archive reproductible, avec son journal de collecte
- la part du panier officiel réellement observée

NON PRODUIT

- un indice des prix à la consommation : la moitié du panier manque
- les loyers pratiqués : le web publie des prix demandés
- les services — école, santé, transport, restauration
- les produits frais, qui ne se vendent pas en ligne
- une pondération nationale, sauf là où l'office la publie

Quelle part du panier officiel peut-on voir ?

Mesuré sur les pondérations officielles ivoiriennes, groupe par groupe ; verdict déclaré et non calculé.



Biens vendus en ligne, hors alimentaire	**16,56 %**
Poste alimentaire 01.1, à partager frais / emballé	**31,17 %**
Partiellement observable (pièces auto, entretien)	**6,75 %**
Hors de portée : loyers, énergie, transport, école, restauration	**45,53 %**

16,6 % à 54,5 %

selon la façon de compter l'alimentaire. Les trois postes les plus lourds sont inaccessibles à eux seuls : restauration 13,27 %, loyers 10,65 %, services de communication 6,71 % — **30,6 %**.

Pas un défaut à corriger : une place de marché vend des biens, et près de la moitié du panier est faite de services et de logement.

INS Côte d'Ivoire — Publication IHPC août 2026, tableau 6 · 50 groupes, somme contrôlée à 10 000

02

Les concepts

Six mots qu'il faut avoir en tête avant de regarder un chiffre.



COICOP 2018 — la nomenclature

La classification de la consommation individuelle par fonction range toute dépense de ménage en **13 divisions**, puis en groupes, classes et sous-classes.

niveau	exemple	ce qu'il sert à faire
division	04 — Logement, eau, électricité, gaz	le niveau de la pondération publiée
groupe	04.1 — Locations réelles pour le logement	le niveau des codes de ce projet
classe	04.1.1 — Loyers payés par les locataires	le niveau d'agrégation d'un indice
sous-classe	04.1.1.0 — Résidence principale	le niveau des variétés du panier
variété	04.1.1.0.10 — chambre dans une baraque	ce qu'un enquêteur relève réellement

DEUX RÉVISIONS COEXISTENT

L'IHPC de l'UEMOA — Côte d'Ivoire, Sénégal — a longtemps suivi la **COICOP 1999 à 12 fonctions** ; la Côte d'Ivoire est passée à **2018 à 13 divisions**. Les deux ne se superposent pas, et le projet le traite explicitement.

Nations unies, COICOP 2018 · nomenclature fournie par l'INS Côte d'Ivoire (625 lignes, 13 divisions)

Panier, variété, SKU — trois identités

Le panier

La liste de ce qu'on relève. Pour un office : **971 variétés** en Côte d'Ivoire. Pour ce dispositif : **25 catégories de site** par pays, choisies et écrites dans un fichier.

La variété

Un article défini assez précisément pour être retrouvé le mois suivant : « loyer brut mensuel d'une maison de 2 à 3 pièces en cour commune avec toilettes ».

Le SKU

La référence interne du vendeur — « AR697FC05DC7BNAFAMZ ». Le nom, l'URL et le prix changent : **le SKU est le seul point fixe** entre deux collectes.

6 762

SKU appariés

Pourquoi le SKU décide de tout : un indice compare **le même article** à deux dates. Sur la collecte ivoirienne des 14 et 18 octobre, 6 762 SKU sont présents aux deux dates — donc 6 762 couples de prix comparables, dont **325 ont bougé**.

Modèles appariés et formules élémentaires

Un indice élémentaire résume l'évolution des prix d'un groupe d'articles. Trois formules, trois réponses différentes.

formule	ce qu'elle calcule	comportement
Jevons	**moyenne géométrique des rapports de prix**	**retenue : insensible aux valeurs extrêmes**
Dutot	rapport des moyennes de prix	sensible au mélange d'articles chers et bon marché
Carli	moyenne arithmétique des rapports de prix	biais à la hausse connu ; calculée pour le montrer



LA RÈGLE DES MODÈLES APPARIÉS

Un article n'entre dans le calcul que s'il est présent **aux deux dates**. Les garde-fous du projet : au moins **3 articles appariés** par strate, un trou de **2 périodes** toléré, et tout rapport de prix hors de **[1/3 ; 3]** écarté — un prix qui triple en un mois est presque toujours une erreur de saisie, pas une inflation.

Pondération — ce qui fait d'une moyenne un indice

Un office mesure par enquête ménages comment un budget se répartit. Sur 100 F dépensés en Côte d'Ivoire :

31,17 F en produits alimentaires

13,27 F en restauration

10,65 F de loyer

pays	alimentaire	logement	unité	contrôle de somme
Côte d'Ivoire	31,93 %	15,50 %	dix-millièmes	10 000,00
Sénégal	49,64 %	12,04 %	dix-millièmes	10 000
Ouganda	27,05 %	10,42 %	pour mille	999,9999

Sans pondération, un tarif d'électricité compterait autant qu'un sachet de riz. Avec elle, on peut dire ce que le dispositif couvre — **le seul chiffre qui dise honnêtement ce qu'il vaut**.

Chaque extraction est refusée si la somme ne tombe pas juste : une somme fausse signifie que la mise en page a changé et que les chiffres lus ne sont pas les bons.

INS Côte d'Ivoire, IHPC août 2026 · ANSD Sénégal, IHPC août 2024 · UBOS, CPI février 2026

robots.txt — la règle qu'on ne contourne pas

Chaque site publie à la racine un fichier qui dit ce qu'un programme peut lire. Le dispositif le respecte sans exception.

situation	ce que fait le dispositif	pourquoi
une règle interdit l'adresse	il n'y va pas	c'est la décision de l'éditeur
le fichier répond 404	il y va	la RFC 9309 vaut autorisation
le fichier est illisible	il n'y va pas	la RFC 9309 impose de tout refuser
le site répond 403 au robot	il n'insiste pas	un blocage anti-robot est une décision, pas un obstacle



LA DISTINCTION QUI A COÛTÉ UNE CAMPAGNE

Un robots.txt **illisible sous charge** est traité comme un refus total. Six pays sur huit ont ainsi été perdus sur une collecte, et le Nigeria une seconde fois sur les loyers — alors que son fichier autorise la page. Le journal nomme désormais la nature du refus.

RFC 9309, Robots Exclusion Protocol · rfc-editor.org/rfc/rfc9309.html

03

L'enchaînement

Des sites web à l'indice, en trois carnets et deux familles de sources.



Le dispositif en une figure

1 · COLLECTER

Carnet 1

8 sites Jumia
25 catégories, 10 pages

→ **68 884 produits**

2 · COMPLÉTER

Carnet 2

offices, régulateurs, PAM
+ 7 sites d'annonces

→ **53 149 relevés**

3 · ANALYSER

Carnet 3

classification COICOP
indices et contrôles

→ **38 règles produit**

CE QUI CIRCULE ENTRE LES CARNETS

`paniers/panier_XX.xlsx`	`outputs/<ISO3>/panel_XX_*.zip`	`outputs/<ISO3>/officiel_XX_*.zip`	`sorties/excel/*.xlsx`
le panier, relu et amendable	l'archive de collecte, typée	relevés, indices, journal	les mêmes données, lisibles

Le carnet 3 lit les **archives**, pas les classeurs Excel : le parquet d'une archive est typé, alors qu'une relecture Excel transforme la division « 01 » en entier 1.

Trois natures de sortie, séparées à dessein

Les relevés

des prix

Ils s'agrègent entre eux : un prix de marché du PAM et un prix Jumia sont deux prix.

Les indices

déjà construits

Les mêler aux prix reviendrait à calculer un indice d'indices. Ils se raccordent **au niveau de la division**.

Le journal

ce que chaque source a donné

Y compris quand elle n'a rien donné. **Une source muette est une information**, pas un silence.

EXEMPLE MESURÉ

Le Sénégal rend **9 624 relevés** et **340 lignes d'indice** — ces dernières viennent de l'ARTP, qui publie un indice des services mobiles par trimestre. Les additionner n'aurait aucun sens.

04

Les trois carnets

Objectif, sources et sorties de chacun — et la classification en détail.



Collecter le commerce en ligne

Relever, sur huit places de marché, le prix de tout ce qui entre dans le panier d'un ménage.

CE QU'UNE LIGNE CONTIENT

`sku`
la référence du vendeur, clé d'appariement

`name`
le libellé affiché, base du classement

`price + currency`
le prix et sa devise, jamais supposée

`category_slug`
la catégorie d'où il vient

`collect_date`
la date du relevé

ce que la collecte fait	comment
découvre l'arborescence du site	menus et rayons, deux niveaux
choisit 25 catégories	une par division COICOP, à tour de rôle
lit 10 pages par catégorie	délai de 2,5 s entre requêtes
écrit une archive et un classeur	rien n'est jamais écrasé

68 884

produits distincts sur 8 pays au 2026-10-28, de 29 catégories en Égypte à 32 en Côte d'Ivoire.

jumia.ci · jumia.sn · jumia.com.ng · jumia.co.ke · jumia.com.gh · jumia.ug · jumia.com.eg · jumia.ma

Compléter par les sources officielles

Le commerce en ligne ne vend ni électricité, ni loyer, ni produit frais. Le carnet 2 va chercher ce qui manque là où c'est publié.

source	ce qu'elle apporte	division	pays
PAM — HDX HAPI	prix de marché, relevés de terrain	01	les 8
OCPV, Sikafinance	prix de détail et de gros	01	CI
ANARE-CI	tarifs d'électricité réglementés	04	CI
CRSE	tarifs réglementés	04	SN
ARTP — IPSM	indice des services mobiles, trimestriel	08	SN
7 sites d'annonces	loyers d'habitation	04	les 8

Résultat : **53 149 relevés**, dont 2 800 annonces immobilières (**2 295 reconnues comme des locations**) et 340 lignes d'indice.

UNE CONDITION DE LA SOURCE

HDX HAPI exige que l'appelant s'identifie : le courriel de contact n'est pas une option du projet mais une condition de la source.

PAM via HDX HAPI · OCPV · Sikafinance · ANARE-CI · CRSE · ARTP (IPSM) · 7 sites d'annonces immobilières

Classer, calculer, contrôler

Le carnet 3 ne collecte rien. Il lit les archives, classe chaque produit, calcule les indices et refuse de livrer un panel douteux.

1 Charger

les archives des carnets 1 et 2, filtrées sur un seul pays : deux devises ne s'additionnent pas.

2 Classer

38 règles produit et 7 règles catégorie, des plongements multilingues et une cascade de modèles de langue. Toutes les réponses sont conservées.

3 Calculer

indices élémentaires par strate, puis agrégation ; Jevons, Dutot et Carli côte à côte.

4 Contrôler

devises mélangées, strates trop minces, rapports hors bornes : autant de motifs de blocage.

UN CONTRÔLE BLOQUANT, PAS UN AVERTISSEMENT

Si le panel mêle deux devises, **utilisable** passe à faux et l'indice n'est pas produit.

Classer : règles, plongements, modèles

Chaque méthode a un domaine où elle est meilleure. Le carnet les mesure côte à côte ; la production les enchaîne : **les règles d'abord, le modèle pour ce qu'elles ne tranchent pas**.

Règles

38 motifs sur le libellé, puis sur le rayon. Gratuites, instantanées, reproductibles — et **aveugles à ce qu'elles n'ont pas prévu**.

Plongements

Un modèle multilingue local rattache le libellé à la classe la plus proche. Sans quota, même résultat à chaque fois ; **vaut par ses références annotées**.

Modèle de langue

Lit le libellé entier et rend classe, quantité et marque en JSON. Coûte, a des quotas, et **ne répond pas deux fois pareil**.

Cascade

Groq, puis Gemini, puis Ollama, puis les règles. Un fournisseur dont le quota est atteint est **mis de côté pour toute la session**.

QUOTA ATTEINT (HTTP 429)

Le client attend le délai que le serveur demande — 4 reprises au plus, jamais plus de 60 s — puis passe au fournisseur suivant. **Un fournisseur écarté ne revient pas** : avant, chaque lot perdait trois appels à lui redemander.

Les règles : des mots-clés, lus dans l'ordre

1 Normaliser
minuscules, sans accents : « Réfrigérateur » = « refrigerateur »

2 Chercher
dans le libellé d'abord, puis libellé + rayon Jumia

3 Première règle
qui correspond, de la plus précise à la plus générale

4 Sinon le rayon
donne la division seule : 05, 08, 13… sans classe

règle (classe COICOP)	mots-clés (extrait)	libellé réel apparié	mot
01.1.1 Pain et céréales	riz · rice · pâtes · pasta · farine · flour	Riz Basmati 900G X20	`riz`
05.3 Appareils ménagers	réfrigérateur · fridge · bouilloire · kettle	Bouilloire électrique 2 litres	`bouilloire`
08.1 Équipement de communication	smartphone · laptop · tv · haut-parleur	Haut Parleur Bluetooth Karaoke 2 Micros	`haut parleur`
13.1 Soins personnels	shampo · savon · soap · dentifrice	Anti-Dandruff Shampoo (500ml) [NG]	`shampo`
03.2 Chaussures	chaussures · shoes · sneakers · sandales	Sandales Nu-pieds pour Homme - Noir	`sandales`
06.1 Médicaments et santé	vitamine · vitamin · paracetamol	Vitamin D3 10,000 IU, 100 Softgels [NG]	`vitamin`
05.6 Entretien du ménage	lessive · detergent · javel · bleach	Détergent Nil Câlin Assouplissant	`detergent`

Chaque règle porte les deux vocabulaires, français et anglais. Libellés relevés sur jumia.ci et jumia.com.ng, octobre 2026.

Où les règles se trompent, et ce qui les rattrape

Quand un mot est là pour une autre raison : **le code donné est faux, et il est donné avec aplomb**.

libellé réel	mot	code donné par la règle	ce que c'est
Machine à Pop Corn électrique (Grande)	`corn`	01.1.1 pain et céréales	appareil ménager, 05.3
NUBIANCE Paris Lait Corps Unifiant & Hydratant	`lait`	01.1.4 lait, fromage, œufs	soin du corps, 13.1
Machine à Café Semi-Automatique Professionnelle	`cafe`	01.2.2 café	appareil ménager, 05.3
Durag En Satin De Soie, Rouge Vin	`vin`	02.1 boissons alcoolisées	effet personnel, 13.2
Rangement De 40 Capsules Nespresso	`capsules`	06.1 médicaments	ustensile de cuisine, 05.4

SANS MOT-CLÉ, LE RAYON DÉCIDE

« Scie Circulaire 2200W » · rayon bricolage → **05**, sans classe

« Hydraulic Trolley Jack » [EG] · Exterior Accessories → **07**

« African Print Playsuit » [NG] · Baby Girls Fashion → **13**, pas 03

CODE COMPLET, RÈGLES SEULES · 28 OCT. 2026

CI	MA	EG	NG
92,4 %	89,9 %	82,7 %	75,8 %

le reste n'a que la division du rayon. Les sites anglophones perdent 10 à 15 points.

Ce qui rattrape : le modèle de langue en mode mixte, et **l'échantillon annoté par pays — seule mesure du taux d'erreur réel**.

Le prompt envoyé au modèle, tel qu'il part

EXTRAIT, MESSAGE SYSTÈME

```
Tu es statisticien des prix à la consommation. Pour chaque produit vendu en
ligne en Afrique, tu renvoies sa classe COICOP 2018, son contenu net, le nomb…

Codes autorisés (le plus fin possible) :
- 01.1.1 : Céréales et produits céréaliers
…
- « quantity » et « unit » décrivent le contenu d'UNE unité (ex. « Eau 1,5L -…
- Unités : kg, g, l, ml, cl, ou "unit" pour les objets comptés (téléphone, co…
- Les dosages (1000mg), capacités de stockage (128Go), puissances (350W) et t…
…
Réponds uniquement en JSON : {"items": [{"id": "...", "coicop": "...",
"quantity": 1.5, "unit": "l", "pack_count": 6, "brand": "...", "confidence": …
```

CE QU'IL CONTIENT

- un rôle : statisticien des prix à la consommation
- les 35 classes autorisées et 13 divisions, avec leur libellé
- les règles de quantité : « 1,5 L × 6 » est un contenu, « 128 Go » non
- le format : JSON, un élément par produit, une confiance 0–1
- le même texte pour Groq, Gemini et Ollama, dans la langue du carnet

lots de 25 produits · **≤ 600 par exécution** · **température 0** · **réponse validée par schéma**

2 788 caractères en français, 2 624 en anglais

Les fournisseurs, observés en campagne

fournisseur	ce qu'il faut	observé en campagne, octobre 2026	ce que fait le carnet
Groq	une clé, gratuite	HTTP 429 dès le troisième lot de 25 sur gpt-oss-20b ; le catalogue a perdu les llama-3.x le 26/10	attend le délai demandé, puis passe à Gemini
Gemini	une clé AI Studio	modèles 2.5 fermés aux nouveaux comptes (HTTP 404) ; les 3.5 répondent ; un 503 « forte demande » ponctuel	l'essai de démarrage adopte le remplaçant que l'API nomme
Ollama	un serveur local, ou la case Colab	Colab : l'installateur exigeait zstd ; 5 à 10 min par session ; qwen2.5:3b, premier appel 99 s sur T4	installe, lance, attend le serveur, télécharge le modèle, dit l'étape qui échoue
règles	**rien**	**toujours là**	**dernier recours**



CATALOGUÉ N'EST PAS ACCESSIBLE

Le menu des modèles se construit à l'exécution : le carnet lit chaque catalogue, écarte ce qui n'est pas un modèle de dialogue, **fait un appel d'essai par candidat** et ne propose que ceux qui ont répondu. Le 28/10 : quatre modèles chez Groq, deux chez Gemini, un chez Ollama — et les 2.5 de Gemini affichés avec la raison de leur refus.

Plongements : faibles seuls, forts annotés

COMMENT ILS CLASSENT

- 800 prototypes pour 35 classes : le libellé français, l'anglais, et un par mot-clé des règles
- chaque libellé rejoint la classe dont le prototype est le plus proche en cosinus ; la similarité est la confiance, l'écart avec la deuxième la marge
- des produits annotés peuvent s'ajouter aux prototypes : un libellé proche d'un exemple annoté prend son code
- modèle par défaut multilingual-e5-large, local, sans quota ; trois autres au menu, jusqu'au plus léger pour un CPU

BANC D'ESSAI : 380 PRODUITS, 29 CLASSES

méthode	classe	division	produits/s
règles	98,7 %	98,7 %	6 396
plongements, zéro-tir	54,2 %	72,9 %	32
plongements + références	**94,2 %**	**97,4 %**	**34**

Le zéro-tir ne fait que reconnaître des libellés de classes. Avec des références annotées, en validation croisée, la même méthode rejoint les règles : **elle vaut par l'échantillon annoté qu'on lui donne**.

Les règles font 99 % ici parce que ce jeu partage leur vocabulaire. Seul un échantillon annoté par pays mesure un vrai catalogue.

Modèle mesuré : multilingual-e5-base · validation croisée à cinq plis

05

Les calculs, par l'exemple

Chaque mesure détaillée sur un cas réel, avec l'intention derrière la formule.



Exemple 1 — un indice élémentaire de Jevons

Trois SKU ivoiriens réellement relevés aux deux dates, et le calcul pas à pas.

SKU	14 octobre	18 octobre	rapport
AR697FC05DC7BNAFAMZ	5 850	3 180	0,5436
AP009EA0RQQ13NAFAMZ	109 000	87 200	0,8000
2N436CM03UMQGNAFAMZ	6 099	5 899	0,9672

LE CALCUL

```
Jevons = (0,5436 × 0,8000 × 0,9672)^(1/3)
       = 0,7452
```

−25,5 %

sur quatre jours pour cette strate de trois articles

L'INTENTION

La moyenne géométrique traite une baisse de moitié et un doublement comme symétriques. Une moyenne arithmétique des rapports — Carli — donnerait **0,7703**, soit un biais de **+2,5 points** à la hausse sur ces trois articles seulement.

jumia_CI_2026-10-18.xlsx, collectes des 14 et 18 octobre 2026

Exemple 2 — du prix affiché au prix comparable

Deux paquets de riz au même prix ne sont pas au même prix. L'extraction de quantité rend les offres comparables.

libellé relevé	quantité lue	unité	prix unitaire
Eau minérale 1,5 L — Pack de 6	9,0	litre	prix ÷ 9
Nouilles — Pack de 40 x 70 g	2,8	kilo	prix ÷ 2,8
Riz brisé — Sac de 25 kg	25,0	kilo	prix ÷ 25
Vitamine C 1000 mg — 30 comprimés	30,0	unité	prix ÷ 30
Smartphone 6,6" 128 Go	1,0	unité	le prix

L'INTENTION, ET LE PIÈGE

Un dosage de 1000 mg, une capacité de 128 Go, une puissance de 350 W ou une diagonale d'écran **ne sont pas des quantités** : les lire comme telles donnerait un prix au kilo absurde. Le prix unitaire n'est donc calculé que là où il a un sens — alimentaire, boissons, entretien, carburants, soins : **01, 02, 05.6, 07.2, 13.1**.

Exemple 3 — classer un produit, et les faux amis

Le classement lit le libellé, puis la catégorie. Les quatre cas ci-dessous ont réellement été mal classés avant correction.

libellé relevé	lu à tort comme	classement juste
Butterfly Baby Potty	beurre — 01.1.5	puériculture — 13.2
Car Cover, Fits To The Size Of The Car	thé — 01.2.3	accessoire auto — 07.2
Papier peint autocollant élégant	gants et collants — 03.1	non classé, faute de mieux
3pcs Milk Feeding Bottle Set	lait — 01.1.4	biberons — 05.4 selon la norme

LA LEÇON

Toutes ces erreurs ont la même forme : **un motif sans frontière de mot**. « butter » attrapait « Butterfly », « gant » attrapait « élé-gant », « collant » attrapait « auto-collant », et le « the » du thé français attrapait l'article anglais. Chaque cas est désormais figé par un test nommé.

Exemple 4 — apparier un loyer à sa variété

Comparer une médiane d'annonces à un prix d'enquête n'a aucun sens. Variété par variété, la comparaison en a un.

	médiane des annonces	prix d'enquête INS	écart
Toutes annonces confondues	850 000 FCFA	114 146 FCFA	× 7,45
Studio apparié	**120 000 FCFA**	**80 639 FCFA**	**× 1,49**
Appartement 2-3 pièces apparié	**300 000 FCFA**	**114 146 FCFA**	**× 2,63**

×7,45 → ×1,5–2,6

écart avant → après appariement

97 %

1 105 annonces sur 1 145 appariées

CE QUE L'APPARIEMENT RÈGLE, ET CE QU'IL LAISSE

Le reste n'était pas un biais de mesure mais une différence de parc — les sites annoncent des villas à Cocody, le panier officiel contient « une chambre dans une baraque ». Reste le standing du quartier, que les annonces ne portent pas : **l'appariement tient sur deux dimensions sur quatre**.

sorties/excel/appariement_loyers_CI.xlsx · INS Côte d'Ivoire, 20 variétés de la sous-classe 04.1.1.0

06

Utiliser et exécuter

Ce qu'il faut installer, ce qu'on tape, et comment reprendre une collecte interrompue.



Le seul prérequis réel

Python 3.10 ou plus

3.12.0 validé sur poste. C'est le seul prérequis : les dépendances s'installent ensuite.

JupyterLab

Pour ouvrir les carnets.

```
pip install jupyterlab
```

PUIS, DANS LE DOSSIER DU PROJET

`pip install -r requirements.txt`	les dépendances du dispositif
`jupyter lab`	ouvre les carnets dans le navigateur
`python -m pytest -q`	277 tests, sans réseau

Lancer une campagne complète

Quatre commandes, dans cet ordre. Chacune écrit ses résultats avant de passer au pays suivant.

1

Proposer les paniers

écrit paniers/panier_XX.xlsx — à relire avant d'aller plus loin

```
python scripts/exporter_paniers.py --contact vous@institut.org
```

2

Collecter le commerce en ligne

plusieurs heures ; une pause de 240 s entre deux pays

```
python scripts/collecter_tous.py --contact … --max-pages 10
```

3

Collecter les sources officielles

quelques minutes par pays ; loyers compris

```
python scripts/collecter_officiel_tous.py --contact …
```

4

Analyser

les archives sont trouvées sans rien taper

```
ouvrir notebooks/3_analyse_FR.ipynb, choisir le pays
```

Reprendre, et ne rien écraser

situation	ce qui se passe
une collecte est interrompue	les pays déjà faits sont écrits ; on relance le reste
un pays échoue	son incident est journalisé, les autres continuent
on relance le même jour	le fichier prend un suffixe _2, _3 — rien n'est remplacé
une page a déjà été lue	le cache la rend sans nouvelle requête
un site refuse par robots.txt	la source est écartée et le motif inscrit au journal



POURQUOI RIEN N'EST JAMAIS ÉCRASÉ

Une collecte de huit mille produits a déjà été perdue sur ce projet — non par un bogue, mais par une commande qui croyait nettoyer. Depuis, les noms portent l'horodatage à la minute et l'écriture s'arrête si le fichier existe. Le revers : **plusieurs passes coexistent**, et seule la dernière fait foi. python scripts/inventaire.py dit laquelle.

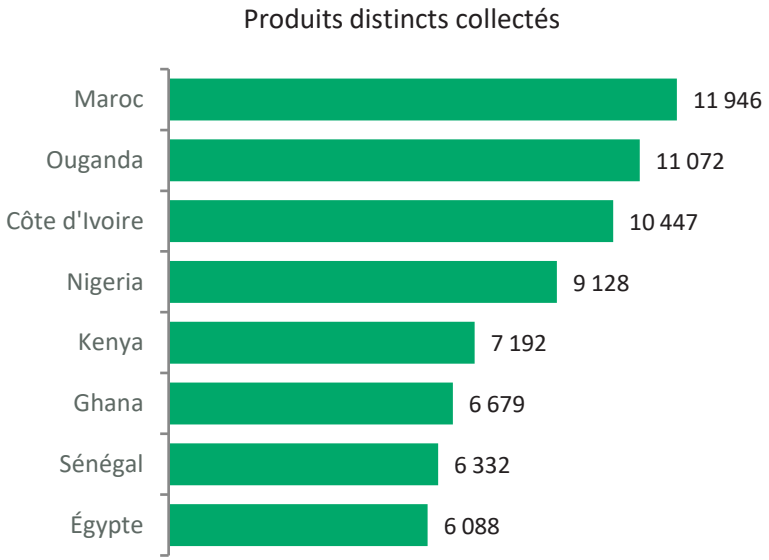
07

Les données collectées

Ce qui est sur disque, pays par pays, à la minute où ce deck a été produit.



Commerce en ligne — carnet 1



pays	site	catég.	devise	jour
Maroc	jumia.ma	39	MAD	2026-10-20
Ouganda	jumia.ug	42	UGX	2026-10-21
Côte d'Ivoire	jumia.ci	32	XOF	2026-10-21
Nigeria	jumia.com.ng	41	NGN	2026-10-20
Kenya	jumia.co.ke	30	KES	2026-10-21
Ghana	jumia.com.gh	37	GHS	2026-10-21
Sénégal	jumia.sn	31	XOF	2026-10-21
Égypte	jumia.com.eg	29	EGP	2026-10-20

Le nombre de catégories est le chiffre à surveiller : il dit combien de rayons le panier a réellement atteints.

Total : **68 884** produits distincts sur 8 pays.

dernière collecte par pays · mesuré le 2026-10-28 12:10

Sources officielles et loyers — carnet 2

pays	relevés	dont loyers	locations	indices	sources
Nigeria	15 729	216	208	0	2
Sénégal	9 624	326	284	340	4
Ouganda	9 107	19	2	0	2
Ghana	6 916	166	166	0	2
Côte d'Ivoire	5 627	1 582	1 145	0	5
Kenya	5 417	209	209	0	2
Égypte	696	249	249	0	2
Maroc	33	33	32	0	1

53 149

relevés au total

2 295

locations parmi 2 800 annonces immobilières

340

lignes d'indice, de l'ARTP sénégalais

Les 340 lignes d'indice sont publiées par trimestre : **elles ne s'additionnent pas aux prix**. Seules les locations entrent dans l'indice : un prix de vente est celui d'un actif, pas d'une consommation.

dernière collecte par pays · mesuré le 2026-10-28 12:10

Paniers et pondérations officielles

pays	catalogue	panier	divisions	poids	officielles
Maroc	1 329	25	8	0	—
Côte d'Ivoire	**1 098**	**25**	**8**	**25**	**oui**
Kenya	958	25	9	3	—
Ghana	947	25	8	4	—
Nigeria	840	25	9	3	—
Sénégal	**666**	**25**	**8**	**25**	**oui**
Ouganda	**467**	**25**	**8**	**25**	**oui**
Égypte	417	25	8	0	—

1 329 → 25

catégories proposées au Maroc → catégories relevées. Le catalogue est tout ce que le site propose ; le panier est ce qu'on relève.

PONDÉRATIONS OFFICIELLES

- **Côte d'Ivoire**
- **Sénégal**
- **Ouganda**

paniers/panier_XX.xlsx · paniers/ponderations_*.csv

08

Portée et limites

Ce que le dispositif apporte, et les cinq endroits où il s'arrête.



Ce que le dispositif apporte

Le coût

Une campagne sur huit pays tient en quelques heures de machine. Aucun enquêteur, aucun déplacement.

La fréquence

Rien n'empêche une collecte hebdomadaire, là où une enquête de terrain est mensuelle.

La traçabilité

Chaque prix porte sa source, son adresse et sa date ; chaque classement porte le mot qui l'a déclenché.

La reproductibilité

Une archive, un journal, 277 tests. Un tiers peut refaire le calcul.

Le complément

Les sources officielles couvrent ce que le web ne vend pas : tarifs réglementés, prix de marché, loyers.

L'honnêteté du chiffre

Le dispositif sait dire quelle part du panier officiel il observe — et c'est rare.

Les cinq limites, chiffrées

limite	ampleur mesurée	conséquence
Le panier ne couvre pas tout	16,6 % à 54,5 % des pondérations ivoiriennes	ce n'est pas un IPC
Les annonces sont des prix demandés	× 1,49 à × 2,63 après appariement	complément, non substitut
Le parc annoncé n'est pas le parc habité	× 7,45 avant appariement	appariement obligatoire
Les catégories sont choisies, non pondérées	25 sur 417 à 1 329 selon le pays	la relecture humaine est requise
Les classements par règles se trompent	38 règles, 4 faux amis corrigés	la table officielle d'exclusions ferait mieux

CE QUE CES LIMITES NE SONT PAS

Elles ne sont pas des défauts d'implémentation qu'un effort supplémentaire lèverait. Une place de marché **vend des biens** : les loyers, l'énergie, les transports, l'école et la restauration — près de la moitié du panier — lui échappent par nature. Le dispositif est utile parce qu'il mesure cette part au lieu de la taire.

Les sources de données, avec leur adresse

source	ce qu'elle donne	adresse
Jumia, 8 pays	prix du commerce en ligne	jumia.ci · .sn · .com.ng · .co.ke · .com.gh · .ug · .com.eg · .ma
PAM via HDX HAPI	prix de marché, 8 pays	hapi.humdata.org/api/v2
OCPV	prix de détail, Côte d'Ivoire	infoprixocpv.com
ANARE-CI	tarifs d'électricité	anare.ci
CRSE	tarifs réglementés, Sénégal	crse.sn
ARTP	indice des services mobiles	artp.sn/indice-des-prix-des-services-mobiles-ispm
Annonces immobilières	loyers, 8 pays	coinafrique.com · propertypro.ng · property24.co.ke · meqasa.com · realestatedatabase.net · propertyfinder.eg · mubawab.ma

Les sources de méthode et de nomenclature

document	ce qu'il fournit	adresse ou origine
COICOP 2018, Nations unies	la nomenclature, 13 divisions	classeur fourni par l'INS Côte d'Ivoire, 625 lignes
Panier CI, INS Côte d'Ivoire	971 variétés officielles, dont 20 de loyer	« COICOP Complète.xlsx », feuille « Panier CI »
Table produits et exclusions	1 196 sous-classes avec leurs exclusions	même classeur, feuille « COICOP Prod&Exclusion »
INS Côte d'Ivoire, IHPC août 2026	pondérations, 50 groupes, somme 10 000	« 8-PUBLICATION IHPC AOUT 2026.xlsx », feuille Page 5
ANSD Sénégal, IHPC août 2024	12 fonctions et 48 groupes, somme 10 000	ansd.sn/sites/default/files/2024-09/IHPC_08_2024.pdf
UBOS, CPI février 2026	13 divisions COICOP, somme 1 000	ubos.org/wp-content/uploads/publications/
RFC 9309	la règle du robots.txt	rfc-editor.org/rfc/rfc9309.html

AFDB – DATA INNOVATION FOR AFRICA (DI4A)

Ce qui reste à faire

01 les pondérations officielles des cinq pays manquants — la méthode est éprouvée sur trois

02 la table quartier → standing, pour achever l'appariement des loyers

03 un jeu de référence annoté avec l'ANSTAT : le premier benchmark COICOP africain, et le juge de paix des trois méthodes

04 une seconde vague de collecte : sans deux dates, pas d'indice

