BAD · DATA INNOVATION FOR AFRICA (DI4A) · SÉRIE PRATIQUE

Passer à l'échelle

Rechercher, agréger et cartographier les mégadonnées avec la suite Elastic (ELK)

Des tuiles Ookla Speedtest à un indicateur infranational de connectivité pondéré par la population

Outils big data pour la statistique officielle — Innover dans la chaîne de valeur des données
Banque africaine de développement – Data Innovation for Africa (DI4A)

SECTION 01

01

Pourquoi changer d’échelle

Quand un portable et pandas ne suffisent-ils plus ?



La chaîne de valeur du big data : six briques

01 Ingestion

Collecter fichiers, API et flux ; valider à l'arrivée.

Téléchargements S3, API, Logstash

02 Stockage

Lac pour les fichiers bruts ; lakehouse pour les tables gouvernées.

Parquet, Delta, Iceberg

03 Traitement

Transformation par lots ou en flux, répartie sur plusieurs machines.

Spark, DuckDB, pandas

EN DÉTAIL

04 Index et recherche

Structures précalculées qui répondent aux filtres en millisecondes.

Elasticsearch, OpenSearch

TRANSVERSAL

Orchestration — Planification, relances et supervision : la mise à jour trimestrielle d'Ookla s'exécute seule (ex. Airflow, cron).

Métadonnées — Quel fichier, quel code, quel mapping ont produit ce chiffre ? Catalogues, Git, versionnage des données.

Lac, lakehouse ou index de recherche : qui fait quoi ?

Lac de données

Répond à : Où est le fichier brut ?

- Fichiers en stockage objet (Parquet, CSV, rasters)
- Schéma à la lecture, coût très faible
- Conserve la source intacte pour l'audit

Lakehouse

Répond à : Quel est l'agrégat officiel ?

- Tables sur le lac (Delta Lake, Apache Iceberg)
- SQL, transactions, retour dans le temps
- Production reproductible des statistiques

Index de recherche

Répond à : Que montre cette sélection, tout de suite ?

- Elasticsearch / OpenSearch
- Index inversé et arbres BKD
- Filtres, texte, géo et tableaux de bord en moins d'une seconde

Par lots

Traiter un jeu de données fini à intervalles — ex. chaque publication trimestrielle d'Ookla.

En flux

Traiter des événements continus à leur arrivée — ex. capteurs, réseaux, transactions.

Le cas Ookla : un jeu de données qui éprouve vos outils

610,8 m
côté d'une tuile à l'équateur (Web Mercator, niveau de zoom 16)

T1 2019
premier trimestre disponible ; nouvelles tuiles chaque trimestre depuis

2 séries
haut débit fixe et mobile, publiés séparément

CHAMPS CLÉS DE CHAQUE TUILE

`quadkey` `avg_d_kbps` `avg_u_kbps` `avg_lat_ms` `tests` `devices` `tile (WKT)`

⚠ **Pourquoi un seul portable peine.** Ookla agrège des centaines de millions de tests mensuels en tuiles, mais un panel multi-pays, multi-trimestres, fixe + mobile grossit vite. Ajoutez la géométrie, les jointures avec les limites et WorldPop, et plusieurs collègues qui interrogent en même temps : c'est la mémoire, non la compétence, qui devient le goulot d'étranglement.

Source : Ookla, README ookla-open-data (GitHub) et Registry of Open Data on AWS — licence CC BY-NC-SA 4.0.

SECTION 02

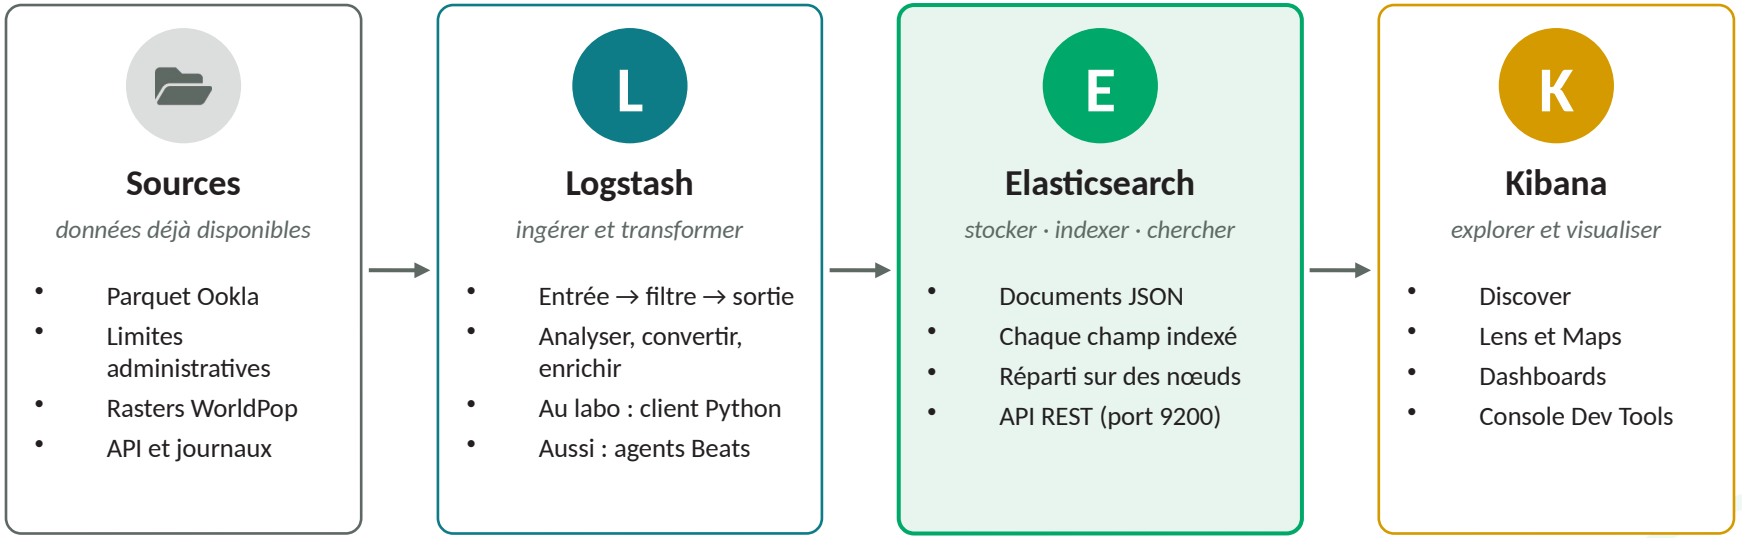
02

La suite Elastic expliquée

Que sont E, L et K, et comment fonctionnent-ils ensemble ?



ELK en une image



De « ELK » à « Elastic Stack ». Beats (agents légers d'envoi de données) a rejoint E, L et K, et Elastic a renommé la famille. On dit encore « ELK » : les deux noms désignent la même suite.

L'idée clé : l'index inversé

DOCUMENTS

- **D1** Kigali · urbain · mobile
- **D2** Musanze · rural · fixe
- **D3** Kigali · rural · mobile

indexer une fois →

TERME → DOCUMENTS

kigali	**D1, D3**
musanze	D2
urbain	D1
rural	**D2, D3**
mobile	D1, D3
fixe	D2

REQUÊTE

`kigali AND rural`

{D1, D3} ∩ {D2, D3}
= {D3}

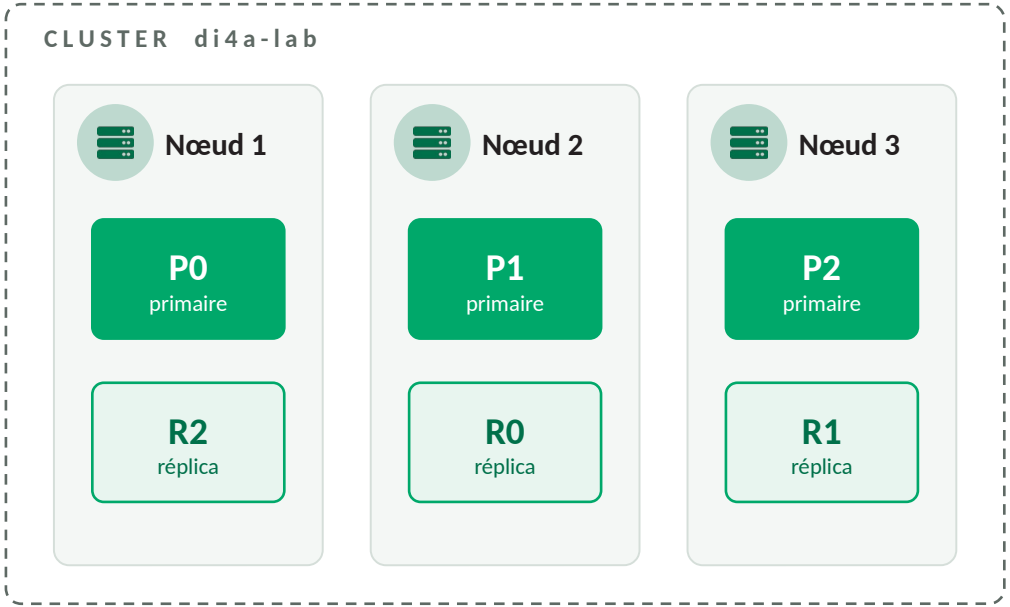
Trouvé sans lire un seul document : on compare seulement deux listes courtes.

Pensez à l'index en fin d'annuaire statistique : on cherche le terme et on va droit aux pages. Nombres et coordonnées utilisent une structure voisine (arbres BKD) pour les intervalles et la géographie. La contrepartie : l'indexation coûte du temps, du disque et de la mémoire au départ, pour des requêtes rapides ensuite.

Parler Elasticsearch : lexique depuis pandas et SQL

EN PANDAS / SQL		EN ELASTICSEARCH	CE QUE CELA SIGNIFIE
`DataFrame / table`	→	**Index**	Une collection nommée, ex. ookla-tiles
`Ligne`	→	**Document**	Une tuile par trimestre, en JSON avec un _id unique
`Colonne`	→	**Champ**	quadkey, avg_d_kbps, tile… chacun est indexé
`dtypes / schéma`	→	**Mapping**	Types déclarés ; en changer impose de réindexer
`df[filtre] / WHERE`	→	**Requête**	Query DSL (JSON) ou ES|QL (texte en pipeline)
`groupby().agg() / GROUP BY`	→	**Agrégation**	Buckets (groupes) et métriques (statistiques)

Anatomie d’un cluster : nœuds, shards et réplicas



ookla-tiles : 3 primaires (P) × 1 réplica (R), jamais sur le même nœud.

Nœud

Un processus Elasticsearch actif, en général une machine.

Shard

Une tranche d’index ; l’unité qui circule entre les nœuds.

Réplica

Une copie sur un autre nœud : résilience et capacité de recherche.

DIMENSIONNEMENT

10–50 Go

par shard, moins de 200 millions de documents chacun. Un ou deux primaires suffisent pour un index Ookla national.

Source : documentation Elastic, « Size your shards ».

SECTION 03

03

Modéliser les données

Comment transformer une tuile Ookla en document interrogeable ?



D’une ligne Parquet à un document JSON enrichi

TEL QUE PUBLIÉ PAR OOKLA

```
quadkey    "3001010303300022"
avg_d_kbps 21450
avg_u_kbps 9870
avg_lat_ms 38
tests      142
devices    57
tile       "POLYGON((30.0586
           -1.9552, ...))"
```

ENRICHIR →

INDEXÉ DANS ELASTICSEARCH

```
{
  "quadkey": "3001010303300022",
  "service_type": "mobile",
  "quarter": "2025-Q2",
  "quarter_start": "2025-04-01",
  "avg_d_kbps": 21450, "avg_u_kbps": 9870,
  "avg_lat_ms": 38, "tests": 142, "devices": 57,
  "admin1": "Kigali City",
  "admin2": "Nyarugenge",
  "pop_worldpop": 4830.5,
  "centroid": {"lat": -1.9525, "lon": 30.0614},
  "tile": "POLYGON((30.0586 -1.9552, ...))"
}
```

- **Trimestre et service** depuis le chemin du fichier
- **admin1 / admin2** jointure spatiale avec les limites
- **pop_worldpop** somme zonale du labo précédent
- **centroid** calculé à partir du polygone

Texte vert = ajouté lors de l’enrichissement

Quadkey et polygone : une vraie tuile de zoom 16 à Kigali. Débits, tests et population sont illustratifs.

Mapping : déclarer le schéma avant d'indexer

```
PUT ookla-tiles
{
  "mappings": {
    "dynamic": "strict",   ◀ refuser l'imprévu
    "properties": {
      "quadkey":       {"type": "keyword"},
      "service_type":  {"type": "keyword"},
      "quarter":       {"type": "keyword"},
      "quarter_start": {"type": "date"},
      "avg_d_kbps":    {"type": "integer"},
      "avg_u_kbps":    {"type": "integer"},
      "avg_lat_ms":    {"type": "integer"},
      "tests":         {"type": "integer"},
      "devices":       {"type": "integer"},
      "admin1":        {"type": "keyword"},
      "admin2":        {"type": "keyword"},
      "pop_worldpop":  {"type": "float"},
      "centroid":      {"type": "geo_point"},
      "tile":          {"type": "geo_shape"}
}}}
```

`keyword` — Valeurs exactes : codes, noms, catégories. Filtres, regroupements, tris.

`integer · float` — Mesures et comptages. Intervalles et statistiques.

`date` — Filtres temporels et histogrammes de dates (quarter_start).

`geo_point · geo_shape` — Coordonnées et polygones pour requêtes spatiales et cartes.

⚠ **Gardez les codes en texte.** Une tuile sur Dakar a le quadkey 0333… ; converti en nombre, il perd son zéro initial sans alerte. Déclarez quadkeys et codes administratifs en keyword.

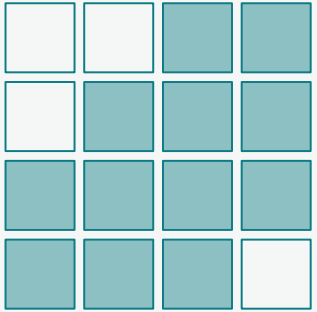
geo_point ou geo_shape ? Deux vues d'une même tuile



geo_point

le centroïde de la tuile

- Compact et très rapide
- Cartes de chaleur, buckets geotile_grid
- Requêtes de distance (≤ 10 km)
- Une tuile frontalière ne compte que d'un côté



geo_shape

le polygone complet de 610 m

- Intersection exacte avec les limites
- Tuiles frontalières comptées des deux côtés
- Rendu fidèle des polygones dans Maps
- Plus lourd à indexer et à interroger

Recommandation : stocker les deux. Le centroïde pour la vitesse, le polygone pour les intersections exactes. Attention à l'ordre des axes : WKT et GeoJSON placent la longitude en premier, comme les fichiers Ookla.

Quatre façons de charger les données, et celle du labo

LABO 1

Client Python

Helper bulk dans un notebook. Scriptable, versionné, reproductible.

Import Kibana

Glisser-déposer un petit CSV ou NDJSON pour explorer vite.

Logstash

Pipelines récurrents : entrée, analyse, enrichissement, sortie.

Pipelines d'ingestion

Traitement dans Elasticsearch : convertir, renommer, enrichir.

```
import pandas as pd
from elasticsearch import Elasticsearch
from elasticsearch import helpers

es = Elasticsearch(URL, api_key=KEY)
df = pd.read_parquet("rw_tiles.parquet")

def actions(df):
    for r in df.to_dict("records"):
        yield {
          "_index": "ookla-tiles",
          # même tuile = même id : pas de doublon
          "_id": f"{r['quadkey']}-"
                 f"{r['quarter']}-mobile",
          "_source": r}

ok, errors = helpers.bulk(
    es, actions(df), chunk_size=5000)
```

SECTION 04

04

Interroger et agréger

Comment poser des questions statistiques au cluster ?



Anatomie d’une requête de recherche

```
GET ookla-tiles/_search
{
  "size": 0,  ◀ 1
  "query": {
    "bool": {
      "filter": [  ◀ 2
        {"term": {"service_type": "mobile"}},
        {"term": {"quarter": "2025-Q2"}}
      ]
    }
  },
  "aggs": {
    "by_region": {
      "terms": {"field": "admin1", "size": 50},  ◀ 3
      "aggs": {
        "mean_dl": {
          "weighted_avg": {  ◀ 4
            "value":  {"field": "avg_d_kbps"},
            "weight": {"field": "tests"}
}}}}}
```

1 **`size: 0`**

Ne renvoyer que les résultats agrégés, pas les milliers de documents sous-jacents.

2 **`filter`**

Conditions oui/non : sans score de pertinence, en cache, rapides. C’est votre clause WHERE.

3 **`terms`**

Un bucket par région : le GROUP BY. Fixez size au-delà du nombre de régions.

4 **`weighted_avg`**

Débit descendant moyen par région, pondéré par le nombre de tests de chaque tuile.

La boîte à outils des agrégations et ses mises en garde

Métrique

calculer une valeur

avg · sum · min · max
≈ mean(), sum()

weighted_avg
≈ np.average(w=)

percentiles
≈ quantile()

cardinality
≈ nunique()

Bucket

former des groupes

terms
≈ groupby(col)

range · histogram
≈ pd.cut()

date_histogram
≈ resample()

geotile_grid
≈ grouper par tuile

Pipeline

agréger des agrégations

derivative
≈ diff()

cumulative_sum
≈ cumsum()

bucket_sort
≈ sort + head()

bucket_script
≈ ratio calculé

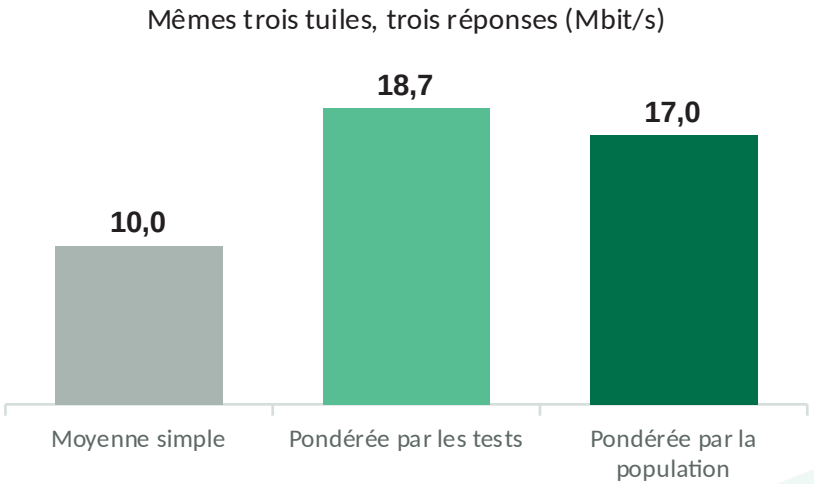
Approchées par construction : cardinality (HyperLogLog++), percentiles (TDigest) et comptages terms multi-shards. Suffisant pour explorer ; vérifiez la précision ou calculez exactement avant de publier.

Un indicateur de connectivité pondéré par la population

FORMULE POUR LA RÉGION r

$$c_r = \Sigma\,(pop_i \times débit_i) \div \Sigma\,pop_i$$

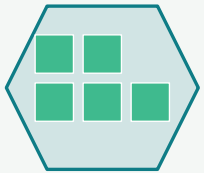
Tuile	Population	Tests	Mbit/s
A · urbaine	5 000	400	**20**
B · périurbaine	1 200	40	**8**
C · rurale	300	5	**2**



Deux règles. Documentez la pondération utilisée : elle change le résultat. Et les tuiles sans test n'ont pas de débit, leur population disparaît : publiez la part de population couverte à côté de l'indicateur.

Chiffres illustratifs à visée pédagogique, non observés. Dans Elasticsearch : weighted_avg avec pop_worldpop comme poids.

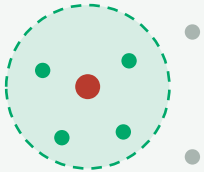
Poser des questions géographiques



`geo_shape`

Quelles tuiles touchent ce district ?

Indicateurs infranationaux, tuiles frontalières comprises.



`geo_distance`

Quelles tuiles à moins de 10 km de ce point ?

Accès autour des hôpitaux, écoles ou marchés.



`geotile_grid`

Combien de tests par cellule ?

Cartes de chaleur et synthèses multi-échelles.

RÉUTILISER UNE LIMITE STOCKÉE PLUTÔT QUE COLLER DES COORDONNÉES

```
"query": {"bool": {"filter": {"geo_shape": {"tile": {
  "indexed_shape": {"index": "admin-boundaries", "id": "RW-02", "path": "geometry"},
  "relation": "intersects"}}}}}
```

ES|QL : la même question, écrite en pipeline

```
FROM ookla-tiles
| WHERE service_type == "mobile"
    AND quarter == "2025-Q2"
| EVAL w = TO_DOUBLE(avg_d_kbps) * tests   ◀ en décimal
| STATS sum_w = SUM(w),
        n_tests = SUM(tests) BY admin1
| EVAL mean_mbps = ROUND(sum_w / n_tests / 1000, 1)
| SORT mean_mbps DESC
| KEEP admin1, mean_mbps, n_tests
```



Chaque étape reçoit la table produite par la précédente, comme un pipe en R ou un chaînage pandas.

Query DSL · *JSON*

- Toutes les fonctions Elasticsearch
- Idéal pour applications et tableaux de bord
- Verbeux, mais précis

ES|QL · *texte en pipeline*

- Se lit comme une recette
- Idéal pour explorer dans Discover
- GA depuis la 8.14 (juin 2024)

Source : Elastic, « Elastic 8.14: Announcing the GA of ES|QL » (juin 2024).

SECTION 05

05

Explorer avec Kibana

Comment les collègues qui ne codent pas obtiennent-ils des réponses ?



Kibana : cinq outils utilisés au labo

Dev Tools

Console pour exécuter des requêtes Query DSL et ES|QL.

Labo 1 : mapping, contrôles d'indexation, premières requêtes

Discover

Parcourir et filtrer les documents ; inspecter les champs.

Labo 2 : contrôles de cohérence, filtres KQL

Lens

Graphiques par glisser-déposer : barres, courbes, tableaux.

Labo 2 : débit par trimestre, fixe vs mobile

Maps

Polygones de tuiles, points et choroplèthes.

Labo 2 : carte régionale, zoom sur les tuiles

Dashboards

Combiner des panneaux avec filtres communs.

Labo 2 : l'explorateur de connectivité

KQL — LE LANGAGE DE LA BARRE DE FILTRES DANS DISCOVER ET DASHBOARDS

```
service_type : "mobile" and tests >= 5 and admin1 : "Kigali City"
```

Labo 2 : construire un explorateur de connectivité

1	2	3	4	5	6
Data view	**Discover**	**Carte**	**Lens**	**Tableau de bord**	**Comparer et publier**
ookla-tiles, champ temporel quarter_start	Vérifier les champs, écarter les tuiles peu testées	Choroplèthe admin1 par débit pondéré	Débit par trimestre, fixe vs mobile	Contrôles région et trimestre	Test face à pandas ; commit sur GitHub
5 min	5 min	15 min	10 min	10 min	15 min

Livrable : *un tableau de bord qui répond à « Où la connectivité mobile est-elle la plus faible, et s'améliore-t-elle ? »* — avec une capture d'écran et l'export des objets sauvegardés (NDJSON) versionnés dans le dépôt de l'équipe.

pandas ou Elasticsearch ? Décidez sur vos propres mesures

Restez sur pandas / DuckDB si…

- Les données tiennent aisément en mémoire
- Un analyste, une analyse ponctuelle ou périodique
- Le script reproductible est le produit
- Aucune compétence serveur pour maintenir un cluster

Passez à Elasticsearch si…

- Les données dépassent une seule machine
- Beaucoup de collègues veulent des réponses interactives
- Requêtes filtrées et spatiales répétées
- De nouvelles données arrivent en continu

VOTRE COMPARATIF — À REMPLIR PENDANT LE LABO 2

Tâche (mêmes données, même question)	Temps pandas	Mémoire pandas	Temps ES	Disque/heap ES
1 · Charger / indexer un trimestre	…	…	…	…
2 · Débit moyen pondéré par région	…	…	…	…
3 · Tuiles touchant un district	…	…	…	…

SECTION 06

06

Gouverner et pérenniser

Que garantir avant de publier depuis un moteur de recherche ?



Qualité et éthique : ce que l'index ne corrige pas

Biais de couverture

Testeurs volontaires : pas un échantillon probabiliste. Biais urbain et smartphone probable.

Petits effectifs

Fixez un seuil minimal de tests ; masquez ou signalez les régions en dessous et indiquez n.

Licence

CC BY-NC-SA 4.0 : citer Ookla, usage non commercial, partage des dérivés à l'identique.

Confidentialité

Pas de microdonnées sur un cluster ouvert. Authentification, accès par rôles, transport chiffré.

Reproductibilité

Mapping, code d'ingestion et requêtes versionnés dans Git avec le millésime des données.

Limites assumées

Un proxy n'est pas une statistique officielle. Écrivez ce qu'il ne permet pas d'affirmer.

Licence : Registry of Open Data on AWS, Speedtest by Ookla Global Fixed and Mobile Network Performance Maps.

Options de déploiement pour un institut statistique

Autogéré

sur site ou centre de données national

- \+ Maîtrise de la localisation des données
- \+ Pas de facture cloud à l'usage
- – Compétences requises : mises à jour, sécurité

Cloud managé

Elastic Cloud ou autre fournisseur

- \+ Opérationnel en minutes, évolutif
- \+ Exploitation assurée par le fournisseur
- – Résidence des données, coût récurrent

OpenSearch

Fork Apache 2.0, Linux Foundation

- \+ Licence entièrement open source
- \+ Les concepts de la séance s'appliquent
- – Les API divergent par endroits

Licences en bref. Depuis septembre 2024, le code d'Elasticsearch et de Kibana est aussi disponible sous AGPLv3 (licence approuvée par l'OSI), à côté de SSPL et de l'Elastic License ; les téléchargements par défaut restent sous Elastic License. Faites valider par votre service juridique.

Sources : Elastic, « FAQ on Software Licensing » et « Elasticsearch is Open Source. Again! » ; Revenera (2025) sur OpenSearch.

Publier sur GitHub : le dépôt que votre équipe emporte

STRUCTURE SUGGÉRÉE

```
di4a-<pays>-connectivity/
├── README.md
├── LICENSE
├── mappings/
│   └── ookla-tiles.json
├── notebooks/
│   ├── 01_index_tiles.ipynb
│   └── 02_benchmark.ipynb
├── queries/
│   ├── by_region.json
│   └── by_region.esql
├── kibana/
│   └── dashboard.ndjson
└── outputs/
    └── connectivity_by_region.csv
```

LE README DOIT PRÉCISER

- **Méthode**
  Enrichissement, choix de pondération, seuil minimal de tests.
- **Sources**
  Ookla, WorldPop et limites, avec millésime et date d'accès.
- **Licences**
  CC BY-NC-SA 4.0 pour les données ; licence distincte pour le code.
- **Limites**
  Biais de couverture, population non couverte, limites du proxy.
- **Reproduire**
  Versions logicielles, commandes, résultats attendus.

Alimente → Statistiques nationales de connectivité · présentations pays

MESSAGES CLÉS

Six idées à rapporter dans votre institut

01 — **Une brique parmi d'autres**

Gardez le brut dans le lac ; indexez un sous-ensemble enrichi.

02 — **L'index inversé est la clé**

Le travail fait à l'indexation se paie en vitesse à la requête.

03 — **Modéliser avant de charger**

Mappings stricts, codes en keyword, point et polygone.

04 — **Pondérer est un choix de méthode**

Documentez-le et publiez la couverture de population.

05 — **Kibana ouvre les données à tous**

Mais choisissez l'outil sur votre propre comparatif.

06 — **Vitesse ne vaut pas qualité**

Licence, confidentialité et limites assumées d'abord.

Sources

Série	Banque africaine de développement – Data Innovation for Africa (DI4A) : série pratique sur les outils big data pour la statistique officielle.
Données Ookla	Ookla — README ookla-open-data, github.com/teamookla/ookla-open-data (taille des tuiles, champs, publications trimestrielles depuis T1 2019).
Licence Ookla	Registry of Open Data on AWS — Speedtest by Ookla Global Fixed and Mobile Network Performance Maps (CC BY-NC-SA 4.0).
Taille des shards	Documentation Elastic — « Size your shards », elastic.co/docs (10–50 Go par shard, moins de 200 millions de documents).
ES|QL	Blog Elastic — « Elastic 8.14: Announcing the GA of Elasticsearch Query Language (ES|QL) », juin 2024.
Licences	Elastic — « FAQ on Software Licensing » et S. Banon, « Elasticsearch is Open Source. Again! » (option AGPLv3, 2024).
OpenSearch	Blog Revenera — « Elastic's Return to Open Source » (janvier 2025) : fork OpenSearch et transfert à la Linux Foundation.

QUESTIONS · PUIS PLACE AU LABO

Des tuiles à l’analyse

Votre cluster tourne. Vos notebooks vous attendent. Rejoignez votre équipe.